МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ «ЛЬВІВСЬКА ПОЛІТЕХНІКА»

Кафедра інформаційних систем та мереж

Методичні вказівки до виконання

КУРСОВОЇ РОБОТИ

з дисципліни

МЕТОДИ ТА ЗАСОБИ ПРИКЛАДНОЇ СТАТИСТИКИ

Львів-2026

1. Мета та загальна концепція

Курсова робота є наскрізним самостійним дослідженням даних у вибраній предметній області, яка полягає в пошуку сирого відкритого датасету та аналізу його походження, структурного очищення, статистичного дослідження, конструювання ознак, побудови відтворюваного конвеєра препроцесингу й фінального модельного експерименту.

Мета роботи – продемонструвати вміння:

– сформулювати прикладну задачу класифікації або регресії;

– знайти та критично оцінити відкритий набір даних;

– дослідити структуру, походження і якість даних;

– виконати структурне очищення без витоку інформації;

– сформувати коректні навчальну і тестову вибірки;

– застосувати методи описової статистики та перевірки гіпотез;

– дослідити залежності між змінними;

– виявити витік цільової або майбутньої інформації;

– створити та обґрунтовано відібрати ознаки;

– побудувати базовий і фінальний конвеєри машинного навчання;

– оцінити їх за допомогою крос-валідації та одноразового тестування;

– інтерпретувати результати, обмеження і практичну цінність дослідження.

Загальна тема:

Дослідження та підготовка даних для розв’язання задачі машинного навчання.

Студент самостійно обирає:

– предметну область;

– практичну задачу;

– відкритий датасет;

– цільову змінну;

– задачу класифікації або регресії.

Відповідальність за придатність датасету та можливість виконати на ньому всі основні частини роботи несе студент.

2. Вимоги до датасету

2.1. Загальні вимоги

Датасет повинен:

– бути відкритим і мати зрозуміле джерело;

– містити від **2000 до 200 000 записів**;

– містити не менше **8 потенційних ознак** без урахування ідентифікаторів і цільової змінної;

– містити щонайменше **2 числові** та **2 категоріальні** ознаки;

– мати чітко визначену цільову змінну;

– дозволяти сформулювати задачу класифікації або регресії;

– містити реальні завдання для структурного очищення;

– потребувати хоча б декількох операцій препроцесингу;

– дозволяти створити щонайменше **дві змістовні нові ознаки**;

– не бути вже повністю очищеним, закодованим і масштабованим;

– не бути класичним навчальним набором на зразок `Iris`, `Titanic` або `House Prices` і т.д.

2.2. Додаткові вимоги до класифікації

– для бінарної класифікації частка меншого класу має становити не менше приблизно 9%, тобто співвідношення кількості об’єктів більшого класу до меншого не повинно перевищувати орієнтовно 10:1. Для багатокласової класифікації співвідношення кількості об’єктів найбільшого класу до найменшого також не повинно перевищувати орієнтовно 10:1;

– кожен клас повинен містити достатньо спостережень для п’ятифолдової крос-валідації;

– критично незбалансовані датасети не використовуються.

2.3. Часові та групові дані

Часові дані дозволені, але датасет має бути багатовимірним і відповідати всім загальним вимогам. Простий одновимірний ряд виду «дата – значення» є недостатнім.

Якщо один об’єкт представлений кількома спостереженнями, студент повинен мати можливість визначити груповий ідентифікатор для коректного поділу даних.

Для часових даних має бути відома часова ознака, за якою можна впорядкувати спостереження.

Якщо значна частина завдань не може бути змістовно виконана через властивості датасету, це свідчить про невдалий вибір і впливає на оцінку.

3. Вимоги до структури курсової роботи

Курсова робота містить:

1. Титульну сторінку.
2. Завдання на курсову роботу.
3. Зміст.
4. Вступ.
5. Розділ 1. Аналіз предметної області та наявних досліджень.
6. Розділ 2. Вибір датасету, первинне профілювання та структурне очищення.
7. Розділ 3. Статистичне дослідження навчальних даних.
8. Розділ 4. Аналіз залежностей, конструювання та відбір ознак.
9. Розділ 5. Препроцесинг і модельний експеримент.
10. Висновки.
11. Список використаних джерел.

Курсова робота виконується у форматі Word (`.docx`). Мінімальний обсяг – **30 сторінок основного тексту**. Верхня межа не встановлюється. Додатки – за бажанням.

Повний програмний код міститься в окремому Jupyter Notebook. У текст роботи включаються лише ключові фрагменти коду, результати, таблиці, графіки та їх змістовна інтерпретація.

ВСТУП

У вступі необхідно подати:

– актуальність теми;

– практичну проблему;

– мету курсової роботи;

– завдання роботи;

– об’єкт дослідження;

– предмет дослідження;

– використані методи;

– практичне значення;

– коротку характеристику структури роботи.

Завдання курсової роботи повинні відповідати змісту її основних розділів і фактично виконаним етапам дослідження.

Результат вступу: чітке пояснення, яку проблему досліджує студент, для чого потрібен прогноз або класифікація та які етапи буде виконано.

РОЗДІЛ 1. АНАЛІЗ ПРЕДМЕТНОЇ ОБЛАСТІ ТА НАЯВНИХ ДОСЛІДЖЕНЬ

1.1. Характеристика предметної області

Необхідно описати:

– досліджуваний об’єкт або процес;

– основні поняття предметної області;

– практичну проблему;

– зацікавлені сторони;

– значення прогнозування або класифікації;

– фактори, які потенційно впливають на цільову змінну;

– можливості застосування машинного навчання.

Опис має бути пов’язаний із вибраною задачею, а не бути загальним переказом відомостей про предметну область.

1.2. Аналіз наукових публікацій

Студент аналізує наявні дослідження, звертаючи увагу на:

– подібні прикладні задачі;

– використані авторами дані;

– одиниці спостереження;

– цільові змінні;

– способи очищення та підготовки даних;

– використані ознаки;

– моделі й метрики;

– отримані результати;

– обмеження досліджень.

Рекомендовано сформувати узагальнюючу таблицю:

Джерело	**Дані**	**Задача**	**Підготовка й ознаки**	**Модель і метрики**	**Результати та обмеження**
[1]	...	...	...	...	...

Вимоги до джерел:

– загалом **10-15 джерел**;

– не менше **6 наукових публікацій**;

– перевага надається джерелам, опублікованим упродовж останніх п’яти років;

– старіші джерела допускаються, якщо вони є фундаментальними або безпосередньо важливими для роботи;

– документація, сторінки датасетів, довідкові вебсторінки та блоги можуть використовуватися, але не замінюють наукових публікацій;

– усі запозичені твердження, таблиці, рисунки, методи та результати повинні мати посилання на джерело.

1.3. Постановка власної задачі

Потрібно визначити:

– що саме прогнозується або класифікується;

– одиницю спостереження;

– цільову змінну;

– момент виконання прогнозу;

– потенційно доступні на цей момент ознаки;

– тип задачі;

– практичний зміст результату;

– основні обмеження.

Розділ завершується висновком про те, які положення з проаналізованої літератури використовуватимуться у власному дослідженні.

Результат розділу 1: обґрунтована постановка задачі, яка спирається на предметну область і наукові публікації.

РОЗДІЛ 2. ВИБІР ДАТАСЕТУ, ПЕРВИННЕ ПРОФІЛЮВАННЯ ТА СТРУКТУРНЕ ОЧИЩЕННЯ

2.1. Результат пошуку датасету

Необхідно подати:

– предметну область;

– повну назву датасету;

– автора або організацію-власника;

– посилання на джерело;

– спосіб і дату отримання;

– формат файлу;

– кількість записів і стовпців;

– період спостережень, якщо він визначений;

– умови або ліцензію використання, якщо вони зазначені;

– цільову змінну;

– тип задачі;

– попередньо виявлені проблеми якості;

– можливі нові ознаки;

– обґрунтування відповідності датасету вимогам курсової роботи.

2.2. Походження даних

Потрібно пояснити:

– як сформовано дані;

– яке джерело є первинним;

– як відбувалося збирання;

– чи містить датасет готову розмітку;

– які обмеження, упередження або похибки могли виникнути.

2.3. Структура датасету

Необхідно визначити:

– одиницю спостереження;

– гранулярність даних;

– ідентифікатори;

– числові, категоріальні, логічні та часові змінні;

– шкали вимірювання;

– характеристику цільової змінної;

– словник основних стовпців.

Рекомендована форма словника:

Стовпець	Зміст	Тип у джерелі	Аналітичний тип	Одиниці/категорії	Роль у дослідженні
...	...	...	...	...	...

2.4. Початкове технічне профілювання

Профілювання виконується на повному сирому датасеті до поділу на `train` і `test`. На цьому етапі дозволено визначити:

– розмір датасету;

– назви стовпців;

– технічні типи даних;

– кількість і частку пропусків;

– кількість точних дублікатів;

– кількість унікальних значень;

– наявність константних стовпців;

– порушення діапазонів, установлених зовнішніми предметними правилами;

– розподіл цільової змінної лише в обсязі, необхідному для вибору коректного способу поділу.

На цьому етапі **не обчислюються і не застосовуються** статистично визначені:

– значення імпутації;

– пороги викидів;

– параметри масштабування;

– правила кодування;

– правила автоматичного відбору ознак.

2.5. Структурне очищення

До структурного очищення належать операції, які не потребують оцінювання статистичних параметрів за даними:

– видалення точних технічних дублікатів;

– виправлення форматів;

– перетворення типів;

– нормалізація написання категорій;

– уніфікація одиниць вимірювання;

– виправлення однозначно встановлених помилок;

– оброблення явно неможливих значень на основі зовнішніх доменних правил;

– позначення помилкових значень як пропущених без їх заповнення;

– вилучення службових стовпців, які однозначно не є ознаками.

Для кожного правила необхідно вказати:

1. виявлену проблему;

2. спосіб її визначення;

3. застосовану дію;

4. кількість змінених, вилучених або позначених записів;

5. обґрунтування рішення.

Пропущені значення цільової змінної не імпутуються. Записи без відомого значення цільової змінної вилучаються до формування `train/test`, а їх кількість і причина вилучення фіксуються у звіті.

На цьому етапі **не виконуються**:

– імпутація середнім, медіаною, модою або моделлю;

– визначення меж викидів за IQR, z-score або іншою статистикою;

– статистичне масштабування;

– кодування категорій для моделі;

– статистичний відбір ознак.

2.6. Контроль після структурного очищення

Повторно перевіряються:

– схема і назви стовпців;

– типи даних;

– дублікати;

– формати;

– категорії;

– доменні правила;

– кількість записів;

– цілісність цільової змінної.

Потрібно порівняти стан даних до і після очищення та сформувати структурно очищену версію датасету. У ній можуть залишатися пропуски й потенційні статистичні викиди – вони опрацьовуються пізніше без витоку даних.

2.7. Формування `train` і `test`

Після структурного очищення дані один раз діляться на:

– `train` – 80%;

– `test` – 20%.

Спосіб поділу:

Тип даних	Спосіб поділу
Класифікація без груп і часу	Стратифікований відтворюваний випадковий поділ
Регресія без груп і часу	Відтворюваний випадковий поділ
Часові дані	Перші 80% за часом – `train`, останні 20% – `test`; без перемішування
Повторні спостереження об’єктів	Груповий поділ, за якого той самий об’єкт не потрапляє до обох частин

Потрібно показати:

– обраний метод і його обґрунтування;

– розміри отриманих частин;

– перевірку відсутності перетину індексів або груп;

– для класифікації – порівняння часток класів;

– для часових даних – часові межі обох частин.

Після формування `test` не використовується для:

– статистичного дослідження;

– перевірки дослідницьких гіпотез;

– вибору ознак;

– вибору способів препроцесингу;

– налаштування моделі;

– порівняння проміжних рішень.

Результат розділу 2: структурно очищений датасет, зафіксовані `train` і `test`, опис усіх правил очищення та підтвердження відсутності витоку між частинами.

РОЗДІЛ 3. СТАТИСТИЧНЕ ДОСЛІДЖЕННЯ НАВЧАЛЬНИХ ДАНИХ

Усі поглиблені статистичні дослідження цього розділу виконуються **тільки на `train`**.

3.1. Первинне статистичне дослідження `train`

Необхідно дослідити:

– описові статистики числових змінних;

– частоти категорій;

– розподіли числових змінних;

– розподіл цільової змінної;

– асиметрію;

– таблиці спряженості;

– змістовні графіки;

– потенційні проблеми навчальних даних.

Кожна таблиця або візуалізація повинна мати назву та змістовний висновок. Не потрібно будувати графік для кожного стовпця без пояснення його користі.

3.2. Аналіз пропусків

Потрібно визначити:

– кількість і частку пропусків;

– розподіл пропусків за ознаками;

– взаємозв’язок між пропусками;

– можливі причини їх виникнення;

– імовірний механізм пропусків: MCAR, MAR або MNAR, якщо це можна обґрунтувати;

– майбутню стратегію імпутації або іншу дію.

На цьому етапі імпутація ще не застосовується. Студент досліджує проблему й обґрунтовує рішення, яке буде реалізовано в конвеєрі.

3.3. Аналіз потенційних викидів

Необхідно виконати:

– візуальну перевірку;

– аналіз за IQR, z-score або іншим доречним методом;

– предметну інтерпретацію підозрілих значень;

– відмежування помилкових значень від рідкісних, але допустимих;

– вибір майбутньої стратегії оброблення.

Обчислені пороги не застосовуються наперед до всього датасету. Якщо статистично визначене оброблення викидів використовується у моделюванні, його параметри мають визначатися лише за відповідною тренувальною частиною.

3.4. Генеральна сукупність і вибірка

Потрібно описати:

– генеральну сукупність;

– доступну вибірку;

– спосіб її формування;

– репрезентативність;

– можливі систематичні зміщення;

– межі поширення отриманих висновків.

3.5. Статистичні гіпотези

Потрібно сформулювати та перевірити **дві змістовні гіпотези**, пов'язані з предметною областю.

Для кожної гіпотези подаються:

1. предметне формулювання;
2. нульова гіпотеза H_0;
3. альтернативна гіпотеза H_1;
4. вибраний статистичний критерій;
5. пояснення відповідності критерію типам даних;
6. перевірка передумов застосування;
7. рівень значущості α;
8. статистика критерію;
9. `p-value`;
10. розмір ефекту, якщо він доречний;
11. статистичний висновок;
12. предметна інтерпретація результату.

Гіпотези перевіряються на `train` і, за можливості, пов’язуються з публікаціями з першого розділу. Формулювання «приймаємо H_0» не використовується: коректно зазначати, що немає підстав відхилити H_0, або що H_0 відхиляється на заданому рівні значущості.

Результат розділу 3: статистична характеристика навчальних даних, обґрунтовані майбутні рішення щодо пропусків і викидів та результати двох перевірок гіпотез.

РОЗДІЛ 4. АНАЛІЗ ЗАЛЕЖНОСТЕЙ, КОНСТРУЮВАННЯ ТА ВІДБІР ОЗНАК

Усі рішення цього розділу приймаються лише на основі `train`, предметних знань і літератури. `Test` не використовується.

4.1. Аналіз залежностей

Залежно від типів змінних можуть застосовуватися:

– кореляція Пірсона;

– кореляція Спірмена;

– таблиці спряженості;

– коефіцієнт V Крамера;

– відношення кореляції;

– взаємна інформація;

– візуальний аналіз.

Необхідно дослідити:

– зв’язки між ознаками;

– зв’язки ознак із цільовою змінною;

– лінійні й нелінійні залежності;

– надлишковість ознак;

– мультиколінеарність;

– можливі ознаки-проксі цільової змінної.

Застосовуються лише методи, що відповідають типам конкретних змінних і постановці задачі. Виявлена статистична залежність не інтерпретується автоматично як причинно-наслідковий зв’язок.

4.2. Перевірка витоку інформації

Необхідно:

– чітко визначити момент виконання прогнозу;

– перевірити доступність кожної ознаки на цей момент;

– виявити прямі похідні цільової змінної;

– знайти післяподієві ознаки;

– проаналізувати службові ідентифікатори;

– вилучити витокові ознаки;

– обґрунтувати кожне рішення.

Рекомендовано подати таблицею:

Ознака	**Доступна в момент прогнозу**	**Ризик витоку**	**Рішення**	**Обґрунтування**
...	так/ні	...	залишити/вилучити	...

4.3. Конструювання ознак

Потрібно створити щонайменше **дві змістовні кандидатні ознаки**.

Для кожної ознаки необхідно подати:

– назву;

– формулу або алгоритм;

– предметне обґрунтування;

– очікуваний зв’язок із цільовою змінною;

– оцінювання фактичної корисності на `train`;

– перевірку можливого витоку.

Правила, вибрані на `train`, надалі однаково застосовуються до `train` і `test`. Детерміновані перетворення одного рядка можуть бути реалізовані окремою функцією. Перетворення, які навчають статистичні параметри або використовують цільову змінну, повинні виконуватися всередині модельного конвеєра, а не наперед на всьому датасеті.

4.4. Формування наборів кандидатних ознак

На основі предметних знань, аналізу залежностей і перевірки витоку потрібно обґрунтовано вилучити:

– службові ідентифікатори;

– ознаки з витоком;

– ознаки, недоступні в момент прогнозування;

– константні та майже константні стовпці;

– дубльовані й явно надлишкові ознаки;

– ознаки без предметного змісту.

Для аналізу надлишковості можуть застосовуватися кореляції, VIF та інші відповідні методи.

Результатом мають бути два набори:

1. **Базовий набір ознак** – допустимі початкові ознаки після вилучення службових, витокових і явно непридатних стовпців, без сконструйованих ознак.

2. **Фінальний набір кандидатних ознак** – базові та сконструйовані ознаки з урахуванням результатів аналізу надлишковості.

Якщо автоматичний відбір за цільовою змінною застосовується додатково, він реалізується всередині модельного конвеєра. Якщо автоматичний селектор не використовується, студент наводить коротке обґрунтування.

Результат розділу 4: перелік залишених, створених і вилучених ознак; базовий та фінальний набори кандидатних ознак; підтвердження відсутності очевидного витоку інформації.

РОЗДІЛ 5. ПРЕПРОЦЕСИНГ І МОДЕЛЬНИЙ ЕКСПЕРИМЕНТ

5.1. Фіксація відтворюваності

На початку Notebook встановлюється єдине значення:

```
SEED = 42
```

Воно використовується для:

– формування випадкового `train/test`;

– перемішування в крос-валідації;

– генераторів псевдовипадкових чисел;

– стохастичних моделей;

– методів повторного семплінгу, якщо вони застосовуються.

Число 42 не має спеціальних статистичних властивостей. Це спільне фіксоване значення, потрібне для відтворюваності результатів.

5.2. Вибір моделі та базовий конвеєр

Студент обирає **один алгоритм машинного навчання**, придатний для своєї задачі, та коротко обґрунтовує цей вибір.

Базовий конвеєр містить:

– просту імпутацію, якщо є пропуски;

– базове кодування категоріальних ознак;

– вибрану модель;

– базовий набір ознак із підрозділу 4.4;

– без спеціального статистичного оброблення викидів;

– без складних трансформацій;

– без сконструйованих ознак.

Усі статистичні параметри базового конвеєра визначаються лише всередині тренувальної частини кожного фолду.

У базовому і фінальному конвеєрах використовується **той самий алгоритм** з однаковими основними гіперпараметрами. Винятком може бути обґрунтоване застосування `class_weight` відповідно до підрозділу 5.4. Мета порівняння – оцінити вплив підготовки даних, а не заміну моделі чи складний підбір гіперпараметрів.

5.3. Фінальний препроцесинг

До фінального конвеєра за обґрунтованої необхідності включаються:

– імпутація;

– статистично визначене оброблення викидів;

– масштабування;

– трансформація розподілів;

– кодування категоріальних ознак;

– оброблення рідкісних категорій;

– фінальний набір кандидатних ознак із підрозділу 4.4;

– необов’язковий автоматичний відбір ознак.

Кожен доданий крок повинен випливати з результатів розділів 3 і 4. Додавання перетворень без перевіреної потреби не вважається перевагою.

Автоматичний селектор, який використовує статистики даних або цільову змінну, повинен бути частиною `Pipeline`. Під час крос-валідації він навчається окремо на тренувальній частині кожного фолду.

Складний пошук кількості ознак, `RFECV`, nested CV та підбір гіперпараметрів селектора не є обов'язковими.

Приклад скелета коду, який можна змінювати відповідно до задачі:

```
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline

SEED = 42

numeric_features = [...]
categorical_features = [...]

numeric_pipeline = Pipeline([
    # Додати імпутацію, якщо вона потрібна
    # Додати масштабування або обґрунтувати відмову від нього
])

categorical_pipeline = Pipeline([
    # Додати імпутацію, якщо вона потрібна
    # Додати кодування
])

preprocessor = ColumnTransformer([
    ("num", numeric_pipeline, numeric_features),
    ("cat", categorical_pipeline, categorical_features),
])

final_pipeline = Pipeline([
    ("preprocessor", preprocessor),
    # ("selector", ...),  # необов'язково
    ("model", ...),
])
```

5.4. Помірний дисбаланс класів

Окремий обов'язковий розділ про незбалансовані класи не вводиться.

Якщо класифікаційний датасет має помірний дисбаланс, студент може:

– не застосовувати балансування, але обрати відповідні метрики;

– застосувати `class_weight`;

– застосувати SMOTE або один інший обґрунтований метод.

Якщо використовується повторний семплінг, він виконується тільки всередині тренувальних фолдів, наприклад через:

```
from imblearn.pipeline import Pipeline as ImbPipeline
```

Балансування всього датасету до поділу або до крос-валідації не допускається. Реальний розподіл класів у `test` зберігається.

5.5. Крос-валідація на `train`

Для оцінювання базового і фінального конвеєрів використовується однакова схема крос-валідації на `train`.

Тип даних	Схема крос-валідації
Класифікація без груп і часу	`StratifiedKFold`, 5 фолдів, перемішування, `random_state=SEED`
Регресія без груп і часу	`KFold`, 5 фолдів, перемішування, `random_state=SEED`
Часові дані	`TimeSeriesSplit`, без випадкового перемішування
Повторні спостереження об’єктів	`GroupKFold` або `StratifiedGroupKFold`, без перетину об’єктів між частинами фолду

Для обох конвеєрів використовуються ті самі фолди й основні метрики. Усі кроки, які навчаються за даними, виконуються окремо всередині кожного тренувального фолду.

5.6. Порівняння результатів крос-валідації

Для класифікації можуть використовуватися:

– accuracy;

– balanced accuracy;

– precision;

– recall;

– F1;

– ROC-AUC або PR-AUC за потреби.

Для багатокласової класифікації потрібно вказати спосіб усереднення метрик, наприклад `macro` або `weighted`.

Для регресії використовуються:

– MAE;

– RMSE;

– R^2.

Одна метрика визначається як **основна** відповідно до практичного змісту задачі. Її вибір потрібно пояснити.

Якщо в scikit-learn використовуються scoring-функції neg_mean_absolute_error або neg_root_mean_squared_error, перед поданням результатів знак метрики потрібно змінити на додатний. Якщо використовується neg_mean_squared_error, після зміни знака отримують MSE; для обчислення RMSE необхідно додатково взяти квадратний корінь. У таблиці MAE та RMSE подаються як невід'ємні величини, для яких менше значення є кращим.

Підсумкова таблиця повинна містити щонайменше:

Конвеєр	**Основна метрика, середнє**	**Стандартне відхилення**	**Додаткові метрики**	**Висновок**
Базовий	...	...	...	...
Фінальний	...	...	...	...

На підставі крос-валідації остаточно фіксується структура фінального конвеєра. Потрібно оцінити не лише середню метрику, а й стабільність результату між фолдами.

5.7. Фінальне навчання та одноразове тестування

Після завершення всіх рішень:

1. зафіксований фінальний конвеєр навчається на всьому train;

2. test використовується один раз для остаточного оцінювання;

3. після перегляду результатів на test структура конвеєра, ознаки та гіперпараметри не змінюються;

4. подаються остаточні метрики;

5. аналізуються типові помилки;

6. результат зіставляється з крос-валідацією та попередніми дослідженнями;

7. формулюється висновок про можливість практичного використання моделі.

Для класифікації подаються релевантні метрики, матриця помилок і аналіз помилок за класами. Для регресії подаються метрики, аналіз залишків або помилок і приклади найбільших відхилень, якщо це змістовно.

Train і test не об'єднуються. Увесь train використовується для фінального fit(), а test залишається незалежною перевіркою.

Результат розділу 5: відтворювані базовий і фінальний конвеєри, їх коректне порівняння на однакових фолдах та остаточна оцінка вибраного конвеєра на незалежному `test`.

ВИСНОВКИ

У висновках потрібно узагальнити:

– результати аналізу предметної області;

– висновки з наукових публікацій;

– придатність вибраного датасету;

– проблеми структурної якості;

– виконані виправлення;

– результати статистичних гіпотез;

– виявлені залежності;

– вилучені витокові ознаки;

– створені ознаки;

– обрані способи препроцесингу;

– результати крос-валідації;

– остаточний результат на `test`;

– практичне значення;

– обмеження;

– можливі напрями продовження дослідження.

Висновки повинні містити конкретні отримані результати, а не повторювати загальні формулювання зі вступу.

ПРАВИЛО «НЕ ЗАСТОСОВУЄТЬСЯ»

Для кожного практичного пункту можливі три результати:

1. Метод застосовано.

2. Перевірку виконано, але проблему не виявлено.

3. Метод не застосовується до конкретного датасету.

У другому і третьому випадках студент:

– наводить коротке пояснення;

– показує програмну перевірку, якщо вона можлива;

– подає отриманий результат;

– формулює висновок.

Не потрібно штучно створювати пропуски, викиди, дисбаланс або інші проблеми, яких немає у вихідних даних. Водночас окремі операції можуть не застосовуватися, але основні розділи повинні мати реальний зміст. Велика кількість незастосовних операцій свідчить про невдалий вибір датасету.

ТЕХНІЧНІ ВИМОГИ ДО JUPYTER NOTEBOOK

Код виконується мовою Python у Jupyter Notebook, рекомендовано в Google Colab. Локальне середовище допускається, але його встановлення, налаштування та виправлення залежностей студент виконує самостійно.

Notebook повинен:

– виконуватися послідовно зверху вниз без ручної зміни проміжних результатів;

– містити всі імпорти й установлення нестандартних пакетів на початку;

– використовувати `SEED = 42` у всіх стохастичних операціях, де це підтримується;

– містити зрозумілі заголовки й короткі текстові пояснення;

– використовувати один явно заданий шлях або змінну для завантаження даних;

– зберігати незмінну сиру версію даних;

– не містити прихованих залежностей від змінних, створених у порушеному порядку виконання;

– містити результати останнього успішного послідовного виконання;

– не використовувати `test` до фінального оцінювання;

– не виконувати статистично навчені перетворення на всьому датасеті до поділу.

Рекомендована структура Notebook:

1. Імпорти, налаштування та SEED.

2. Завантаження сирих даних.

3. Початкове технічне профілювання.

4. Структурне очищення.

5. Контроль після структурного очищення.

6. Формування train/test.

7. Статистичне дослідження train.

8. Аналіз пропусків і потенційних викидів на train.

9. Перевірка статистичних гіпотез на train.

10. Аналіз залежностей на train.

11. Перевірка витоку.

12. Конструювання ознак.

13. Формування базового та фінального наборів ознак.

14. Базовий конвеєр.

15. Фінальний конвеєр.

16. Крос-валідація обох конвеєрів на train.

17. Порівняння результатів.

18. Навчання фінального конвеєра на всьому train.

19. Одноразове оцінювання на test.

20. Підсумкові висновки.

Для виконання роботи можуть використовуватися pandas, NumPy, SciPy, statsmodels, scikit-learn, imbalanced-learn, Matplotlib, Seaborn та інші обґрунтовано вибрані бібліотеки.

ПОДАННЯ РЕЗУЛЬТАТІВ У WORD

Для кожного логічного блоку студент подає:

1. постановку завдання;

2. коротке пояснення методу;

3. основний фрагмент коду;

4. підсумковий результат;

5. аналіз та висновок.

Не потрібно вставляти скріншот після кожного рядка або дрібної перевірки. Скріншот, консольний вивід, таблиця або графік потрібні там, де формується змістовний результат, наприклад:

– `df.info()` або підсумок профілювання;

– таблиця описових статистик;

– звіт аудиту якості;

– графіки розподілів;

– порівняння до і після структурного очищення;

– таблиця перевірки статистичних гіпотез із назвою тесту, статистикою та `p-value`;

– кореляційна матриця або інша візуалізація залежностей;

– таблиця створених і вилучених ознак;

– матриця помилок або `classification_report`;

– таблиця метрик регресії;

– підсумкова таблиця крос-валідації;

– фінальні метрики на `test`.

У Word достатньо ключових фрагментів коду і результатів. Повний код та повна послідовність виконання повинні міститися в Notebook. Усі таблиці й рисунки мають бути читабельними, пронумерованими, підписаними та згаданими в тексті.

МАТЕРІАЛИ, ЯКІ ПОДАЄ СТУДЕНТ

Студент подає:

1. курсову роботу у форматі `.docx`;

2. Jupyter Notebook (`.ipynb`) із повним кодом і збереженими результатами виконання;

3. вихідний датасет у незміненому вигляді;

4. структурно очищений датасет;

5. фінальний аналітичний датасет після структурного очищення, конструювання та обґрунтованого вилучення ознак.

Фінальний аналітичний датасет містить:

– структурно очищені записи;

– початкові ознаки, залишені для моделювання;

– сконструйовані ознаки;

– цільову змінну;

– без службових і витокових стовпців.

Статистично навчені перетворення не застосовуються наперед до всього фінального файлу. Імпутація, масштабування, статистичне оброблення викидів, кодування та автоматичний відбір виконуються всередині конвеєра після поділу даних.

Назви файлів мають однозначно вказувати на їхній зміст. Рекомендовано використовувати таку структуру:

```
coursework_<прізвище>/
├── <прізвище>_курсова_робота.docx
├── <прізвище>_coursework.ipynb
└── data/
    ├── raw_<назва>.<формат>
    ├── structurally_cleaned_<назва>.csv
    └── analytical_<назва>.csv
```

ОЦІНЮВАННЯ КУРСОВОЇ РОБОТИ

Максимальна оцінка – **100 балів**.

Складова	Що оцінюється	Максимум
Вступ	Актуальність, мета, завдання, об’єкт, предмет, методи, практичне значення та узгодженість зі змістом	5
Розділ 1	Аналіз предметної області, якість роботи з науковими джерелами, узагальнення публікацій і коректна постановка власної задачі	10
Розділ 2	Обґрунтування датасету, походження, словник даних, профілювання, структурне очищення, контроль якості та коректний `train/test`	20
Розділ 3	Статистичне дослідження `train`, аналіз пропусків і викидів, генеральна сукупність, дві коректні перевірки гіпотез та інтерпретація	15
Розділ 4	Аналіз залежностей, перевірка витоку, щонайменше дві змістовні нові ознаки, обґрунтоване формування базового і фінального наборів	15
Розділ 5	Базовий і фінальний конвеєри, відсутність витоку, однакова крос-валідація, вибір метрик, порівняння та одноразове оцінювання на `test`	20
Загальні висновки та оформлення матеріалів	Конкретність висновків, узгодженість Word і Notebook, читабельність результатів, повнота та відтворюваність поданих файлів	5
Захист	Розуміння власних рішень і коду, пояснення методів, інтерпретація результатів, відповіді на запитання	10
Разом		**100**

Загальні принципи виставлення балів

– Повний бал за складову нараховується за правильне виконання, предметне обґрунтування, відтворюваний код і змістовну інтерпретацію.

– Частково правильне, неповне або недостатньо обґрунтоване виконання оцінюється пропорційно.

– Наявність коду без аналізу результату не є повним виконанням пункту.

– Твердження без програмної перевірки там, де вона потрібна, не є повним виконанням.

– Помилки, що створюють витік даних або роблять фінальну оцінку нечесною, впливають на бали за всі пов’язані пункти розділів 2, 4 і 5.

– Якщо Notebook не відтворює результати, наведені у Word, відповідні результати не можуть бути оцінені як повністю виконані.

– Використання непридатного датасету не звільняє від вимог роботи і зменшує бали за невиконані або формально виконані складові.

ЗАХИСТ КУРСОВОЇ РОБОТИ

Під час захисту студент повинен:

1. коротко представити предметну область, задачу і датасет;
2. пояснити основні проблеми якості даних та виконані виправлення;
3. обґрунтувати спосіб поділу на `train/test`;
4. пояснити дві статистичні гіпотези та отримані результати;
5. показати основні залежності, вилучені й сконструйовані ознаки;
6. пояснити структуру базового і фінального конвеєрів;
7. порівняти результати крос-валідації;
8. представити остаточний результат на `test`;
9. відповісти на запитання щодо коду, методів, результатів та обмежень.

Студент повинен орієнтуватися у власному Notebook і вміти пояснити призначення ключових фрагментів коду. Наявність результату без розуміння способу його отримання знижує оцінку за захист.

ФІНАЛЬНИЙ ЧЕКЛІСТ СТУДЕНТА

Перед поданням перевірте:

– [ ] Тема відповідає задачі класифікації або регресії.

– [ ] Датасет відповідає вимогам щодо розміру, структури та типів ознак.

– [ ] Джерело, дата отримання та умови використання вказані.

– [ ] Є щонайменше 10 джерел, із них не менше 6 наукових публікацій.

– [ ] Сирий датасет збережено без змін.

– [ ] Структурне очищення відокремлено від статистичного препроцесингу.

– [ ] `Train/test` сформовано один раз коректним для даних способом.

– [ ] Після поділу `test` не використовувався для дослідницьких рішень.

– [ ] Статистичне дослідження, гіпотези й аналіз залежностей виконано тільки на `train`.

– [ ] Перевірено можливий витік кожної ознаки.

– [ ] Створено щонайменше дві змістовні нові ознаки.

– [ ] Сформовано базовий і фінальний набори ознак.

– [ ] Базовий і фінальний конвеєри використовують той самий алгоритм та однакові основні гіперпараметри.

– [ ] Усі навчені перетворення виконуються всередині конвеєра.

– [ ] Обидва конвеєри порівняно на однакових фолдах.

– [ ] Основну метрику вибрано та обґрунтовано.

– [ ] `Test` використано один раз після фіксації фінального конвеєра.

– [ ] Notebook послідовно виконується зверху вниз і містить збережені результати.

– [ ] Результати у Word відповідають результатам Notebook.

– [ ] Подано всі п’ять обов’язкових матеріалів.

– [ ] У тексті є висновки до кожного логічного блоку і загальні висновки.

– [ ] Усі використані джерела мають коректні посилання.